

Aplicação de Modelos de Machine Learning para Manutenção Preditiva em Máquinas Industriais

Karen dos Anjos Arcoverde

Departamento de Engenharia de Telecomunicações

Universidade Federal Fluminense

Niterói, Brasil

karenarcoverde@id.uff.br

Vitor Hugo Ferreira

Departamento de Engenharia Elétrica

Universidade Federal Fluminense

Niterói, Brasil

vhferreira@id.uff.br

Resumo—Este trabalho apresenta a aplicação de modelos de aprendizado de máquina para prever falhas em máquinas industriais, utilizando dados de telemetria, manutenção e falhas anteriores. A abordagem proposta visa melhorar a eficiência da manutenção preditiva, reduzindo custos operacionais e tempos de inatividade não planejados. Foram utilizados modelos de classificação e regressão para prever a ocorrência de falhas e estimar o tempo até a próxima falha, respectivamente.

Palavras-chave—manutenção preditiva, aprendizado de máquina, regressão, classificação, previsão de falhas

Abstract—This paper presents the application of machine learning models to predict failures in industrial machines, using telemetry data, maintenance records, and previous failures. The proposed approach aims to improve the efficiency of predictive maintenance by reducing operational costs and unplanned downtimes. Classification and regression models were used to predict the occurrence of failures and to estimate the time until the next failure, respectively.

Index Terms—predictive maintenance, machine learning, regression, classification, failure prediction

I. INTRODUÇÃO

A. Motivação

A manutenção reativa, tradicionalmente adotada em muitos setores industriais, apresenta limitações significativas, como altos custos operacionais e interrupções inesperadas na produção. Embora a manutenção preventiva reduza a frequência dessas interrupções, sua aplicação indiscriminada pode gerar gastos excessivos com a substituição de componentes ainda em condições de uso. Nesse contexto, a manutenção preditiva desponta como uma alternativa promissora, permitindo antecipar falhas e otimizar recursos. No entanto, a complexidade dos dados gerados pelos sistemas industriais e a carência de ferramentas analíticas robustas tornam sua implementação desafiadora. A integração de técnicas de aprendizado de máquina tem potencial para superar essas barreiras, possibilitando a análise de padrões complexos nos dados operacionais. Apesar disso, há uma lacuna na validação prática desses modelos em ambientes industriais reais, o que reforça a necessidade de iniciativas que conectem teoria e prática de forma efetiva.

B. Objetivos do Trabalho

O objetivo principal deste trabalho é desenvolver modelos de aprendizado de máquina para prever falhas em máquinas industriais utilizando dados históricos, apoiando o planejamento

e a execução de estratégias de manutenção. Para alcançar esse objetivo, serão implementados modelos de classificação, com foco na previsão de falhas, e de regressão, para estimar o tempo até a próxima falha. Esses modelos permitirão identificar fatores críticos que influenciam a degradação dos equipamentos, oferecendo insights valiosos para a tomada de decisão. Além disso, o trabalho busca combinar as análises exploratórias, os modelos de regressão e de classificação em um processo integrado de apoio à manutenção preditiva. Por fim, serão realizados ajustes e refinamentos na solução desenvolvida, incluindo a aplicação de critérios estatísticos para validação dos resultados e a otimização dos modelos para garantir eficiência e precisão em ambientes industriais reais.

II. REVISÃO BIBLIOGRÁFICA

A manutenção preditiva tem ganhado destaque na indústria devido à sua capacidade de prever falhas e otimizar processos operacionais, reduzindo custos associados a manutenções reativas e preventivas [2]. Estudos demonstram a eficácia de modelos de aprendizado de máquina na previsão de falhas em sistemas complexos, utilizando dados históricos e em tempo real [3]. Técnicas como regressão e classificação têm sido amplamente aplicadas para análise de variáveis como vibração, pressão, tensão e rotação, buscando identificar padrões que precedem falhas [4].

Contudo, a integração dessas abordagens em fluxos industriais práticos ainda é desafiadora, dada a complexidade dos dados e a necessidade de ferramentas analíticas robustas [5]. A literatura existente destaca a importância da análise exploratória de dados (AED) para identificar tendências e outliers, bem como a necessidade de validação rigorosa dos modelos propostos em ambientes reais [3]. Este trabalho busca contribuir para essa lacuna, implementando e avaliando modelos preditivos em um cenário industrial baseado em dados reais de telemetria, falhas, manutenção e erros [2].

III. METODOLOGIA PROPOSTA

A metodologia proposta neste trabalho combina etapas bem definidas para implementar um modelo preditivo robusto e aplicável a cenários industriais. A primeira etapa envolve a coleta de dados, realizada a partir do repositório Predictive Maintenance [1]. O conjunto de dados inclui informações

sobre vibração, pressão, tensão, rotação e idade das máquinas, coletadas por sensores em ambientes industriais. Esses dados, obtidos em intervalos regulares, são fundamentais para identificar padrões e prever falhas em equipamentos.

A etapa seguinte é a análise exploratória de dados (AED), que permite entender as características das variáveis disponíveis e como elas se relacionam com os eventos de falha. Nesse processo, os dados são limpos para remover duplicidades e inconsistências. Em seguida, estatísticas descritivas como média, desvio padrão e mediana são calculadas. Uma ferramenta importante nesse contexto é a utilização das funções de distribuição cumulativa (CDF), que ajudam a compreender a distribuição das variáveis e sua relação com a ocorrência de falhas.

Após a AED, realiza-se o pré-processamento dos dados, que inclui a agregação e a normalização. Os dados são agregados para consolidar medições relacionadas e evitar redundâncias, enquanto transformações logarítmicas são aplicadas para normalizar as variáveis e reduzir o impacto de valores extremos. Isso garante uma base sólida e confiável para o treinamento dos modelos preditivos.

Os modelos preditivos são então implementados em duas abordagens complementares. Modelos de regressão são utilizados para estimar o tempo até a próxima falha, enquanto modelos de classificação identificam a probabilidade de ocorrer uma falha em até vinte quatro horas. Ambos os métodos são validados por métricas, como por exemplo, MSE, precisão e recall, proporcionando uma visão abrangente do desempenho.

Na regressão, utiliza uma rede neural para prever o tempo até a falha de máquinas, com base em entradas de telemetria (vibração, voltagem, pressão e rotação). A rede foi projetada com uma única camada oculta contendo 64 neurônios, utilizando a função de ativação ReLU. Além disso, foi aplicada regularização L2 à camada oculta, penalizando pesos excessivamente grandes para reduzir o risco de sobreajuste, o que é uma preocupação comum ao trabalhar com conjuntos de dados ruidosos ou limitados.

Para reforçar a capacidade do modelo de generalizar, foi adicionada uma camada de Dropout após a camada oculta. Com uma probabilidade de 20%, essa camada desativa aleatoriamente 20% dos neurônios durante o treinamento, ajudando a reduzir a dependência de combinações específicas de pesos. A camada de saída, por sua vez, contém apenas um neurônio com ativação linear, permitindo que a rede preveja valores contínuos diretamente, sem restrições. Essa configuração é essencial para problemas de regressão como este, onde o objetivo é prever o tempo até a falha.

Os hiperparâmetros foram escolhidos para balancear desempenho e estabilidade. O otimizador Adam foi utilizado devido à sua capacidade de combinar as vantagens de métodos como SGD e RMSProp, permitindo ajustes rápidos e precisos nos pesos. A taxa de aprendizado foi definida como 0,0005, um valor relativamente baixo que garante atualizações suaves e evita oscilações nos gradientes. A função de perda escolhida foi o erro quadrático médio (MSE), que penaliza erros maiores de forma mais significativa, tornando-a ideal para previsões

de valores contínuos. Além disso, o erro percentual médio absoluto (MAPE) foi usado como uma métrica complementar para oferecer uma perspectiva percentual do desempenho do modelo.

O treinamento foi configurado com até 100 épocas e um tamanho de lote de 32, mas foi utilizado um callback de parada antecipada (Early Stopping), monitorando a perda de validação. Caso a perda de validação não melhorasse após 10 épocas consecutivas, o treinamento seria interrompido, e os pesos da melhor época seriam restaurados. Essa estratégia não apenas economiza tempo, mas também previne que o modelo se ajuste excessivamente aos dados de treino.

Na classificação, utiliza o modelo XGBoost (Extreme Gradient Boosting), uma técnica baseada em árvores de decisão que combina o método de boosting para aumentar a precisão preditiva ao minimizar os erros iterativamente. O modelo tem como objetivo prever falhas futuras (falha ocorrendo dentro de 24 horas) com base em entradas de voltagem, pressão, rotação, vibração, idade, contagem de erros e contagem de manutenções.

O número de árvores (`n_estimators`) foi definido como 200, permitindo que o modelo capturasse padrões mais complexos nos dados. Cada árvore foi limitada a uma profundidade máxima (`max_depth`) de 5, o que controla a complexidade individual das árvores e evita que elas aprendam características específicas demais, reduzindo o risco de sobreajuste. Além disso, foi configurada uma taxa de aprendizado (`learning_rate`) de 0.1, que controla o impacto de cada nova árvore no modelo final, garantindo um aprendizado estável e gradual. Esses hiperparâmetros, combinados, ajudam a construir um modelo que equilibra bem o viés e a variância.

Para introduzir regularização adicional e prevenir o sobreajuste, foram utilizados os parâmetros `subsample` e `colsample_bytree`, ambos configurados com um valor de 0.7. Isso significa que, em cada iteração, 70% dos dados de treino e 70% das variáveis foram utilizados para construir cada árvore. Essa abordagem reduz a dependência do modelo em amostras ou variáveis específicas, aumentando a robustez geral. O parâmetro `gamma`, definido como 0.1, foi utilizado para evitar divisões desnecessárias nos nós das árvores ao exigir uma redução mínima na função de perda para que uma divisão ocorresse. Além disso, o peso mínimo exigido para subdividir um nó (`min_child_weight`) foi ajustado para 5, garantindo que divisões só ocorram quando houver suporte suficiente em termos de dados, o que ajuda a lidar com outliers.

Durante o treinamento, o modelo construiu árvores sequencialmente, corrigindo os erros residuais das árvores anteriores. Essa abordagem iterativa permitiu que o modelo otimizasse gradualmente a função de perda, ajustando-se aos padrões complexos nos dados. Após o treinamento, o desempenho foi avaliado nos conjuntos de treino e teste utilizando métricas de classificação, como precisão (`precision`), cobertura (`recall`), F1-score e acurácia geral. Essas métricas forneceram uma visão detalhada de como o modelo se comportou em prever falhas futuras, identificando com maior precisão os padrões associados a eventos de falha.

IV. RESULTADOS

Nesta seção, discutiremos os resultados obtidos por meio da análise exploratória de dados e visualizações específicas. Primeiramente, analisamos as medidas estatísticas descritivas das variáveis, que fornecem uma visão geral da distribuição dos dados. Em seguida, apresentamos as funções de distribuição cumulativa (CDF) para as variáveis principais: pressão, vibração, rotação e tensão. Essas distribuições ajudam a identificar diferenças associadas a tipos específicos de falhas.

Adicionalmente, exploramos padrões temporais de falhas, como sua ocorrência ao longo do dia, e realizamos uma análise detalhada da frequência de falhas por máquina. Por fim, identificamos os tipos predominantes de falhas por máquina, o que contribui para personalizar estratégias de manutenção preditiva.

Os resultados apresentados nesta seção fornecem uma base sólida para entender os fatores que influenciam o desempenho das máquinas e os padrões de falhas associados. A seguir, detalhamos as observações e implicações obtidas com base nos dados analisados.

Na Tabela I, são apresentadas as medidas estatísticas descritivas das variáveis tensão, rotação, pressão e vibração. A média e a mediana estão próximas para todas as variáveis, indicando distribuições relativamente simétricas. O desvio padrão mostra que a rotação e a tensão têm maior dispersão em relação às suas médias, enquanto a vibração e a pressão são mais concentradas. Os valores mínimos e máximos destacam a ampla faixa de operação para cada variável, como a rotação, que varia de 138,43 a 695,02, e a tensão, de 97,33 a 255,12. Os percentis (25%, 50% e 75%) fornecem mais detalhes sobre a distribuição dos dados, como a vibração, onde 75% das observações estão abaixo de 43,79. Essas estatísticas são fundamentais para identificar padrões e diferenças nas variáveis relacionadas ao desempenho e às falhas das máquinas.

Tabela I
MEDIDAS ESTATÍSTICAS DESCRITIVAS.

Medida	Tensão	Rotação	Pressão	Vibração
Média	170,78	446,58	100,86	40,39
Mediana	170,61	447,54	100,43	40,24
Desvio Padrão	15,51	52,69	11,05	5,37
Mínimo	97,33	138,43	51,24	14,88
Máximo	255,12	695,02	185,95	76,79
25%	160,31	412,27	93,50	36,78
50%	170,61	447,54	100,43	40,24
75%	181,01	482,16	107,56	43,79

A Figura 1 apresenta as funções de distribuição cumulativa (CDF) para os diferentes tipos de falha em relação à pressão. É evidente que o tipo de falha “comp3” apresenta um comportamento distintamente diferente, com uma faixa de pressão significativamente maior em comparação com as outras categorias. Isso sugere que falhas desse tipo podem estar associadas a condições operacionais de alta pressão. Por outro lado, as falhas “comp1”, “comp2” e “comp4” têm distribuições mais próximas, indicando uma faixa de pressão semelhante.

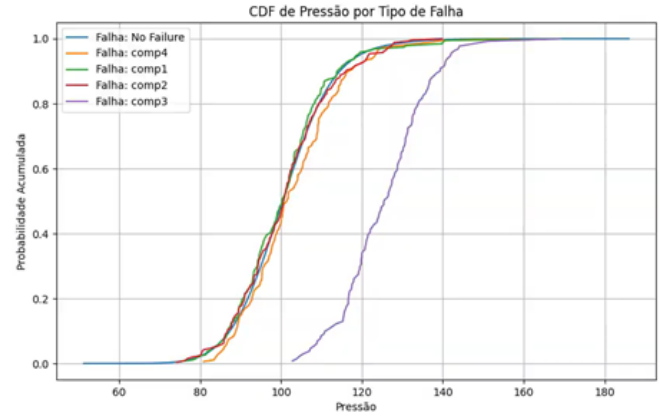


Figura 1. CDF de Pressão por Tipo de Falha.

Na análise da vibração da Figura 2, o tipo de falha “comp4” novamente demonstra um comportamento distinto, com vibrações acumulando-se em níveis mais altos. Falhas como “comp1”, “comp2” e “comp3” mostram distribuições muito próximas, indicando que essas falhas são mais difíceis de diferenciar apenas com base nos níveis de vibração. Isso reforça a necessidade de combinar variáveis para melhorar a capacidade preditiva.




Figura 2. CDF de Vibração por Tipo de Falha.

A distribuição de rotação da Figura 3 destaca que as falhas do tipo “comp2” estão associadas a níveis mais baixos de rotação, enquanto “comp1”, “comp3” e “comp4” possuem distribuições mais homogêneas. Essa característica sugere que a rotação pode ser uma variável chave para identificar falhas específicas como “comp2”.

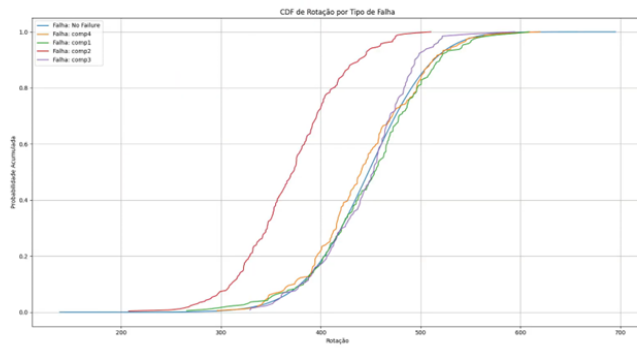


Figura 3. CDF de Rotação por Tipo de Falha.




Figura 5. Número de falhas por horas do dia.

A análise da tensão da Figura 4 mostra que a falha “comp1” se destaca, apresentando distribuição acumulativa em nível significativamente diferente. A tensão mais alta está associada a falha “comp1”, enquanto tensões mais baixas predominam em “comp2”, “comp3” e “comp4”.

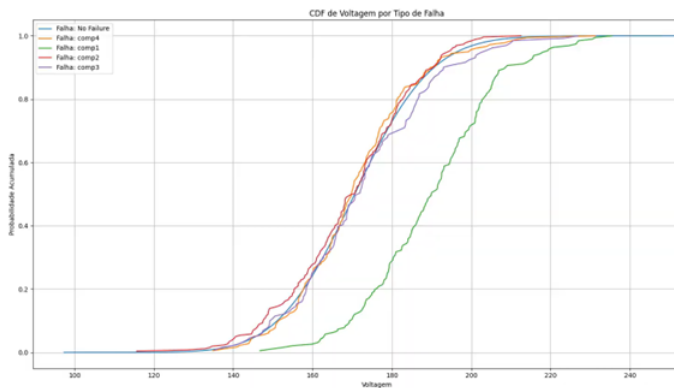


Figura 4. CDF de Voltagem por Tipo de Falha.

A Figura 6 ilustra o número total de falhas por ID de máquina. Algumas máquinas apresentam uma maior frequência de falhas, indicando que podem estar operando sob condições mais severas ou que têm problemas específicos de manutenção. Esses padrões são úteis para priorizar inspeções e ajustes em máquinas mais propensas a falhas. Por exemplo, a máquina 99 é a que possui maior quantidade de falhas.




Figura 6. Número de falhas por ID da máquina.

Esta Figura 5 mostra a distribuição de falhas ao longo do dia. A maior concentração de falhas ocorre em torno das seis horas da manhã, indicando uma possível dependência de horário relacionada à operação da máquina ou à carga de trabalho nesse período. Durante o restante do dia, o número de falhas é significativamente menor.

A Figura 7 categoriza as máquinas com base no tipo de falha predominante. É evidente que certos tipos de falhas, como “comp1”, são mais comuns em algumas máquinas específicas, enquanto outras máquinas apresentam falhas mais diversificadas. Essa análise fornece insights importantes para a personalização de estratégias de manutenção, priorizando os tipos de falha mais frequentes por máquina. Por exemplo, a máquina 99 apresenta predominância da falha “comp2”.




Figura 7. Tipo de Falha Predominante e ID da máquina.

A análise inicial buscou explorar possíveis relações lineares entre as variáveis de telemetria pelas Figuras 8 e 9, manutenção e erros com o tempo até a falha por meio de métodos de regressão. No entanto, os gráficos de dispersão demonstraram uma ausência de padrões lineares claros entre as variáveis independentes e dependentes, indicando que as relações entre os dados eram complexas e não lineares. Dado esse cenário, optou-se por abordar o problema como uma tarefa de classificação binária, visando prever se uma falha ocorrerá dentro de um período de 24 horas.

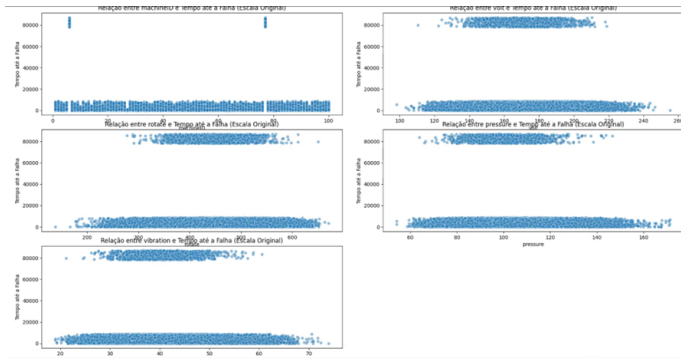


Figura 8. Relação entre ID da máquina, voltagem, rotação, pressão e vibração por tempo até a falha.

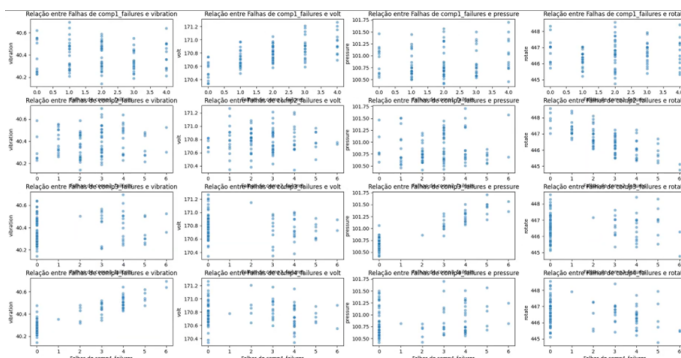


Figura 9. Relação entre falhas comp1, comp2, comp3 e comp4 por vibração, voltagem, pressão e rotação.

Os resultados obtidos para o modelo de regressão baseado em rede neural demonstram um desempenho satisfatório no

conjunto de treino na Tabela II, mas apresentam desafios significativos no conjunto de teste na Tabela III. Durante o treinamento, o modelo alcançou um Loss de 1.3181 e um MSE de 1.3176, indicando que ele conseguiu capturar padrões relevantes dos dados, com uma precisão relativamente boa no conjunto de treino. O MAPE de 13.6817% reforça que, em média, os desvios relativos das previsões em relação aos valores reais foram moderados, o que é aceitável para problemas de regressão envolvendo variáveis altamente dinâmicas, como telemetria e falhas.

No entanto, no conjunto de teste, o modelo apresentou métricas significativamente piores, com um Loss e MSE de 40.711.028,1491 e um MAPE elevado de 343,4851%. Esses valores sugerem que o modelo sofreu com problemas de generalização, possivelmente devido a uma combinação de variabilidade nos dados de teste, insuficiência de regularização e/ou subamostragem do conjunto inicial. A discrepância entre o desempenho no treino e no teste indica que o modelo pode ter sobreajustado os dados de treino, capturando ruídos ou padrões específicos que não são generalizáveis.

Tabela II
RELATÓRIO DE REGRESSÃO NO CONJUNTO DE TREINO.

Época	Loss	MSE	MAPE
31	1.3181	1.3176	13.6817

Tabela III
RELATÓRIO DE REGRESSÃO NO CONJUNTO DE TESTE.

Loss	MSE	MAPE
40711028.1491	40711028.1491	343.4851

O modelo de classificação foi avaliado tanto no conjunto de treino na Tabela IV quanto no conjunto de teste na Tabela V, e as métricas de desempenho mostram um equilíbrio limitado entre as classes positivas (falhas previstas corretamente) e negativas (ausência de falhas). A precisão geral do modelo foi moderada, com uma accuracy de 55% em ambos os conjuntos. Esse valor reflete a complexidade do problema e sugere que as variáveis disponíveis capturam parcialmente os padrões associados às falhas.

No conjunto de treino, o modelo obteve precision, recall e F1-score de 55%, 34%, e 42% para a classe 0 (sem falha), enquanto para a classe 1 (falha), os mesmos valores foram 55%, 74% e 63%, respectivamente. Esses resultados indicam que o modelo tem maior capacidade de identificar corretamente as falhas do que de identificar a ausência de falhas, como demonstrado pelo maior recall para a classe 1. Essa característica pode ser relevante em cenários onde prever falhas é mais crítico do que prever corretamente a ausência de problemas, mas a baixa precisão para a classe 0 indica que o modelo também gerou um número considerável de falsos positivos.

No conjunto de teste, os valores de precision, recall e F1-score foram semelhantes, confirmando que o modelo conseguiu manter seu desempenho em dados não vistos, com pouca

degradação na generalização. No entanto, a macro average do F1-score, de 52%, destaca que o desempenho geral do modelo ainda pode ser melhorado, especialmente no equilíbrio entre as classes.

Tabela IV
RELATÓRIO DE CLASSIFICAÇÃO DO CONJUNTO DE TREINO.

Classe	Precision	Recall	F1-Score	Support
0	0.55	0.34	0.42	511186
1	0.55	0.74	0.63	558140
Accuracy	0.55			
Macro Avg	0.55	0.54	0.53	1069326
Weighted Avg	0.55	0.55	0.53	1069326

Tabela V
RELATÓRIO DE CLASSIFICAÇÃO DO CONJUNTO DE TESTE.

Classe	Precision	Recall	F1-Score	Support
0	0.54	0.34	0.42	127628
1	0.55	0.74	0.63	139704
Accuracy	0.55			
Macro Avg	0.54	0.54	0.52	267332
Weighted Avg	0.54	0.55	0.53	267332

É possível construir gráficos com essas previsões para auxiliar na manutenção preditiva. O gráfico da Figura 10 apresenta o tempo até a falha para cada máquina, medido em horas. Aqui, o eixo X representa os IDs das máquinas, e o eixo Y indica o tempo até a falha. As barras estão ordenadas com base no maior tempo até a falha, o que permite visualizar quais máquinas levaram mais tempo para apresentar uma falha. Esse gráfico é útil para priorizar a manutenção preventiva em máquinas com menor tempo até a falha, fornecendo uma perspectiva complementar sobre a durabilidade operacional das máquinas. Por exemplo, a máquina 85 foi a que teve menor tempo até a falha, entende-se que as falhas ocorrem mais rápido nela.




Figura 10. Tempo até a falha por ID da máquina.

O gráfico da Figura 11 mostra o número de falhas futuras (ocorrendo dentro de 24 horas) corretamente previstas pelo modelo. Os IDs das máquinas estão dispostos no eixo X, enquanto o eixo Y exibe a quantidade de falhas corretamente previstas para cada máquina. As barras estão ordenadas em ordem decrescente, iniciando com a máquina que teve o maior

número de falhas previstas corretamente. Esse gráfico ajuda a identificar quais máquinas apresentaram mais ocorrências de falhas previstas corretamente pelo modelo, destacando o desempenho em prever falhas críticas em curto prazo. Por exemplo, a máquina 99 foi a que apresentou maior quantidade de falhas futuras corretamente previstas.




Figura 11. Número de falhas ocorrendo dentro de 24 horas corretamente previstas por ID da máquina.

Desse modo, é possível concluir que as previsões feitas podem fornecer apoio a manutenção preditiva, uma vez que preveem as máquinas que dão falhas em menor tempo e possivelmente em quantas horas será a próxima falha e prever uma falha futura que pode ocorrer dentro de 24 horas.

V. CONCLUSÃO E TRABALHOS FUTUROS

A aplicação de modelos de aprendizado de máquina para manutenção preditiva apresentou resultados promissores, mas também destacou desafios importantes. A análise exploratória de dados (AED) foi fundamental para compreender as características das variáveis de telemetria e sua relação com as falhas. Durante essa etapa, foram calculadas estatísticas descritivas, como média, mediana e desvio padrão, além da análise de funções de distribuição cumulativa (CDF), que ajudaram a identificar padrões operacionais e associações com tipos específicos de falhas.

Os resultados exploratórios também mostraram padrões temporais relevantes, como a maior concentração de falhas por volta das seis horas da manhã, sugerindo dependência com a carga de trabalho ou condições operacionais específicas. A análise das máquinas revelou que algumas apresentavam maior frequência de falhas, como a máquina 99, destacando a necessidade de estratégias de manutenção personalizadas para cada equipamento. Essas observações reforçam o valor das análises exploratórias no entendimento dos dados e na formulação de modelos preditivos.

A aplicação de modelos de aprendizado de máquina demonstrou grande potencial para melhorar estratégias de manutenção preditiva em ambientes industriais. No entanto, os resultados obtidos indicam desafios significativos na implementação prática. A abordagem de regressão mostrou-se limitada devido à ausência de relações lineares claras entre as variáveis analisadas, enquanto os modelos de classificação

apresentaram desempenho moderado, com uma acurácia de 55% tanto no conjunto de treino quanto no de teste. Apesar disso, os modelos foram capazes de identificar padrões importantes, principalmente no que diz respeito à previsão de falhas, com recall elevado para a classe positiva (74%), essencial em cenários críticos para reduzir o tempo de inatividade e os custos operacionais.

Os desafios identificados, como a baixa precisão para a classe negativa e dificuldades em capturar relações complexas, abrem caminho para trabalhos futuros. Uma direção promissora inclui o refinamento da engenharia de features, explorando variáveis adicionais ou derivadas que possam melhorar a discriminação entre as classes. Além disso, técnicas de balanceamento de classes, como oversampling ou under-sampling, podem ser empregadas para mitigar os efeitos do desbalanceamento nos dados de treino.

Outra possibilidade está na integração de abordagens mais avançadas de aprendizado de máquina, como redes neurais profundas para classificação ou métodos baseados em aprendizado causal, que podem capturar relações mais complexas nos dados. Por fim, a validação em ambientes industriais reais será essencial para garantir a aplicabilidade e o impacto prático das soluções desenvolvidas. Isso inclui a implementação de protótipos que combinem modelos preditivos e sistemas de monitoramento em tempo real para suportar decisões de manutenção de forma eficiente e precisa.

REFERÊNCIAS

- [1] BOHADANA, Ricardo. *Predictive Maintenance Repository*. Disponível em: <https://github.com/ricardobohadana/PredictiveMaintenance?authuser=0>.
- [2] Hamaide, V., Joassin, D., Castin, L., Glineur, F. A two-level machine learning framework for predictive maintenance: comparison of learning formulations. arXiv preprint arXiv:2204.10083, 2022.
- [3] Vanderschueren, T., Boute, R., Verdonck, T., Baesens, B., Verbeke, W. Prescriptive maintenance with causal machine learning. arXiv preprint arXiv:2206.01562, 2022.
- [4] Hurtado, J., Salvati, D., Semola, R., Bosio, M., Lomonaco, V. Continual Learning for Predictive Maintenance: Overview and Challenges. arXiv preprint arXiv:2301.12467, 2023.
- [5] Kane, A. P., Kore, A. S., Khandale, A. N., Nigade, S. S., Joshi, P. P. Predictive Maintenance using Machine Learning. arXiv preprint arXiv:2205.09402, 2022.